

MÀSTER UNIVERSITARI EN BIOINFORMÀTICA I BIOESTADÍSTICA

PROGRAMARI PER A L'ANÀLISI DE DADES - PAC1

Objectiu: Validar els coneixements adquirits durant els laboratoris:

- LAB 1. Introducció al llenguatge R, Rstudio i RMarkdown, i
- LAB 2. Estadística descriptiva i gràfics amb R.

Data de lliurament: 25 de març de 2026.

Format: *CognomEstudiant_PAC1.html* o *CognomEstudiant_PAC1.pdf*

Lliurament: Mitjançant el registre d'avaluació continua de l'aula.

Comentaris previs a la realització de la PAC1

1. El fitxer lliurat haurà d'estar en format HTML o PDF i haurà d'haver-se generat necessàriament mitjançant R Markdown. En cas de no complir aquest requisit, la qualificació final no podrà ser superior a 5.
2. Encara que a les preguntes no hi aparegui de manera explícita, és obligatori incloure el **codi utilitzat** en el fitxer generat.
3. Es recomana fer els exercicis de la PAC1 íntegrament dins l'entorn de treball **RStudio**.

Enunciat

Secció 1. Importació, gestió de dades i configuració (2,5 punts)

1.1. (0,75 punts) Crea un document R Markdown amb una capçalera que inclogui títol, autor, data i taula de continguts (toc: true). El document que presentis haurà de reflectir aquesta configuració.

1.2. (0,5 punts) Instal·la i carrega el paquet MASS. Carrega el conjunt de dades biopsy i recodifica els noms de totes les columnes perquè siguin exactament els següents (en minúscules): id, thickness, size_uni, shape_uni, adhesion, epi_size, bare_nuclei, chromatin, normal_nuclei, mitosis i class.

1.3. (0,5 punts) Identifica la presència de valors perduts. Crea un nou data frame anomenat biopsy_clean eliminant totes les files que continguin valors nuls. Indica quantes files s'eliminen i discuteix breument quins problemes pot comportar treballar únicament amb els casos complets.

1.4. (0,75 punts) Exporta el data frame depurat a un fitxer anomenat biopsy_clean.csv sense incloure els números de fila. Abans de l'exportació, reflexiona breument sobre si la variable id és necessària per a l'anàlisi i quins problemes ètics podria comportar mantenir-la. Pren una decisió al respecte.

Secció 2: Estructures de dades i manipulació avançada (2 punts)

En els apartats següents s'haurà de treballar amb el conjunt de dades generat a la secció anterior.

- 2.1. (0,5 punts) Crea una llista que contingui: un vector amb els noms de les variables, el resum estadístic de la variable `thickness` i el nombre total d'observacions. Mostra el contingut del segon element de la llista.
- 2.2. (0,5 punts) La variable `class` és un factor amb els nivells "benign" i "malignant". Recodifica les etiquetes d'aquest factor a "benign_case" i "malignant_case" (en minúscules).
- 2.3. (0,5 punts) Selecciona únicament les files que tinguin un valor de `thickness` superior a 7 i pertanyin a la class "malignant_case".
- 2.4. (0,5 punts) Insereix una fórmula en LaTeX que representi la mitjana i una imatge externa relacionada amb la biologia cel·lular.

Secció 3: Estadística descriptiva i contrastos (2,5 punts)

- 3.1. (0,5 punts) Calcula la mitjana, la mediana i la desviació típica de la variable `size_uni`. Desa els resultats en un vector. Indica breument si els valors obtinguts suggereixen una distribució aproximadament simètrica o no.
- 3.2. (0,5 punts) Crea una nova variable anomenada `high_mitosis`, que prengui el valor "yes" si el valor de mitosis és superior a 5 i "no" en cas contrari. Explica quin tipus de variable és `high_mitosis` i per què pot resultar útil transformar una variable numèrica en categòrica en aquest context.
- 3.3. (0,5 punts) Genera una taula de contingència entre la variable `class` i la nova variable `high_mitosis`. Comenta breument quin patró s'observa a la taula.
- 3.4. (1 punt) Aplica el test més adequat per analitzar la relació entre la mitosi i la malignitat. Interpreta el valor p.

Secció 4: Visualització avançada i modelització lineal (3 punts)

- 4.1. (0,5 punts) Amb el paquet `ggplot2`, crea un gràfic de dispersió que relacioni `size_uni` (eix x) amb `shape_uni` (eix y). Els punts han de tenir colors diferents segons la variable `class`. Comenta breument què suggereix el gràfic sobre la separació entre classes i si sembla que hi ha relació entre `size_uni` i `shape_uni`.
- 4.2. (1 punt) Calcula el model de regressió lineal per predir `size_uni` en funció de `thickness`. Mostra el resum del model i comenta el coeficient de determinació. Representa

el núvol de punts amb la recta de regressió superposada i comenta si l'ajust sembla raonable.

4.3. (1 punt) Genera un gràfic per avaluar la normalitat dels residus. Contrasta l'assumpció de normalitat. Interpreta conjuntament el resultat del test i del gràfic.

4.4. (0,5 punts) Presenta en una sola finestra un histograma de la variable mitosis i un boxplot de thickness segons la class, personalitzant els colors. Comenta breument les principals característiques d'ambdós gràfics.